

# 使用不确定性感知输出长度预测调度 LLM 推理

Haoyu Zheng<sup>1</sup> Yongqiang Zhang<sup>2</sup> Fangcheng Fu<sup>3</sup> Xiaokai Zhou<sup>1</sup> Hao Luo<sup>1</sup> Hongchao Zhu<sup>2</sup>  
Yuanyuan Zhu<sup>1</sup> Hao Wang<sup>1</sup> Xiao Yan<sup>4</sup> Jiawei Jiang<sup>1,5</sup>

## 摘要

在 LLM 推理调度中，最短作业优先 (SJF) 原则具有优势：优先处理输出较短的请求，以避免队首 (HOL) 阻塞。现有方法通常为每个请求预测单一输出长度，以便调度。我们认为，这种点估计与 LLM 推理的随机解码过程不匹配：输出长度本质上不确定，取决于何时采样到序列结束 (EOS) token。因此，每个请求的输出长度应拟合为一个分布，而非单一数值。通过深入分析经验数据和随机解码过程，我们观察到输出长度服从重尾分布，可使用 log-t 分布拟合。在此基础上，我们提出一个简单指标——尾部膨胀期望 (Tail Inflated Expectation, TIE)，替代 SJF 调度中的输出长度。该指标利用 log-t 分布的尾部概率修正其期望，以考虑请求生成输出的风险。为评估 TIE 调度器，我们与三个强基线比较；结果表明，TIE 在线推理中将每 token 延迟降低 2.31 $\times$ ，在离线数据生成中将吞吐量提高 1.42 $\times$ 。

## 1. 引言

大型语言模型 (LLM) 支撑聊天机器人、内容生成、科学推理等大量人工智能应用。ChatGPT (OpenAI, 2022)、Gemini (Google DeepMind, 2023) 和 Claude (Anthropic, 2023) 等流行服务每天处理数十亿次推理请求 (Chatterji et al., 2025)。因此，核心问题是如何调度这些请求执行，而调度目标随场景不同而变化。在线服务（如聊天机器人和编程助手）为保证服务质量 (QoS)，优先考虑首 token 时间 (TTFT) 和每 token 延迟 (PTLA) 等延迟指标；离线处理（如合成数据生成 (SDG) 和数据清洗）则强调吞吐量，力求最大化




图 1. LMSYS-Chat-1M 数据集 (Zheng et al., 2024) 中第一个提示词的输出长度分布。柱形表示 256 次生成得到的输出长度，红色曲线为拟合的 log-t 分布。

一个时间窗口内处理的请求数。

已有观察表明，输出长度预测可能存在较大误差 (Chen et al., 2025b)，部分方法采用迭代预测和抢占调度应对。例如，TRAIL (Shahout et al., 2025) 使用轻量线性分类器，在生成每个 token 后预测输出长度，并抢占被预测会生成长输出的请求。ELIS (Choi et al., 2025) 采用类似方法，但使用外部编码器，将预测间隔扩展为 50 个 token。由于频繁预测和可能的抢占，这些方法开销可能较高 (vLLM, 2025; Zhong et al., 2024)。现有方法的局限促使我们提出：

准确预测输出长度的根本困难是什么？如何产生高质量预测来帮助调度？

**我们的洞见和方案。** 核心洞见是：现有点估计（即为每个请求预测一个输出长度）不匹配 LLM 推理的随机解码过程。具体而言，LLM 推理在每一步解码中随机采样一个 token，其概率由此前 token 决定；输出长度则取决于何时采样到 EOS token。因此，每个请求的输出长度本质上不确定，同一请求多次执行可能得到不同长度，如图 1 所示。为考虑解码过程的内在随机性，应为每个请求拟合输出长度分布，而非单一数值。

通过分析真实请求，我们观察到输出长度服从重尾分布，可用 log-t 分布 (Cassidy et al., 2010) 有效拟合。我们还在关于 LLM 解码过程的一些温和假设下证明这一性质。例如，图 1 中 log-t 分布的 Kolmogorov-Smirnov (KS) 检验 (Massey Jr, 1951) p 值为 0.8898，

<sup>1</sup>School of Computer Science, Wuhan University, Wuhan, China <sup>2</sup>Dameng Database Co., Ltd., Wuhan, China <sup>3</sup>School of Artificial Intelligence, Shanghai Jiao Tong University, Shanghai, China <sup>4</sup>Institute for Math and AI, Wuhan University, Wuhan, China <sup>5</sup>School of Computer Science, Central China Normal University, Wuhan, China. Correspondence to: Xiao Yan <yanxiaosunny@whu.edu.cn>, Jiawei Jiang <jiawei.jiang@whu.edu.cn>.

表明拟合质量较高。为预测各请求的 log-t 分布参数，我们使用一个简单模型：通过微调的 DeBERTa-v3-base (He et al., 2021; 2023) 提取请求语义，再将所得嵌入输入 MLP。

为将拟合分布用于调度，我们设计尾部膨胀期望 (TIE) 指标。其依据是：调度应考虑请求可能生成输出并造成 HOL 阻塞的风险，因此应惩罚重尾请求。TIE 使用尾部期望 (即  $\mathbb{E}[X | X \geq \text{VaR}_\alpha^X]$ ) 修正 log-t 分布的期望 (即  $\mathbb{E}[X]$ )，其中  $\text{VaR}_\alpha^X$  (风险价值) 是尾部百分位数，从而纳入风险。所得 TIE 调度器实现简单，只需将 SJF 中的输出长度替换为 TIE。

我们全面评估 TIE 调度器在在线和离线推理中的表现，并测试多个数据集和模型。结果表明，相对于表现最佳基线，TIE 在在线聊天场景中每 token 延迟降低 2.31 $\times$ ，在离线 SDG 任务中将吞吐量提高 1.42 $\times$ 。微实验也表明，TIE 中的尾部期望修正改善性能，而且调度器能较好地泛化到不同数据集和模型。

**贡献.** 本文贡献如下：

- 我们观察到现有方法对请求输出长度进行点估计，并认为这与 LLM 解码中的随机 token 采样不匹配。
- 为考虑输出长度的内在不确定性，我们提出拟合 log-t 分布而非单一数值。除调度外，此方法也可能有益于 KV 缓存管理和成本估计等涉及输出长度的用途。
- 基于拟合的 log-t 分布，我们设计了 TIE 调度器<sup>1</sup>，它实现简单，且在实验中表现较强。

## 2. 相关工作

**LLM 服务系统.** 如上所述，现有 LLM 系统通常使用先到先服务 (FCFS) 调度，存在 HOL 阻塞。连续批处理 (Yu et al., 2022) 是重要进展，避免长请求阻塞整个批次。但队列级阻塞仍待解决：长请求仍可能阻塞队列中等待的短请求，增加平均延迟并降低吞吐量。

**LLM 推理调度.** 为缓解队列级阻塞，近期研究探索了基于 SJF 的策略。除第 1 节讨论的 SSJF 和 LTR 外，还提出其他预测调度方法 (Jin et al., 2023; Zheng et al., 2023)。但如前所述，LLM 输出的内在不确定性使准确长度预测困难。

为缓解不确定性，一种潜在优化路径是基于迭代预测的抢占调度 (Shahout et al., 2025; Choi et al., 2025; Wu et al., 2024)。但如第 1 节所述，其开销显著。我们的调度方法在考虑输出不确定性的同时，避免频繁重新预测和抢占的开销。

**LLM 输出长度预测.** 除请求调度外，LLM 输出长度预测还用于 KV 缓存管理 (Horton et al., 2025) 和成本估计 (Piotrowski et al., 2025)。除 SSJF、LTR 等基于提示词的预测器外，其他方法通过嵌入预测长度，并在生成时迭代修正。TRAIL (Shahout et al., 2025) 将中

间层嵌入输入线性分类器预测长度。LGR (Piotrowski et al., 2025) 在 TRAIL 基础上，将多个中间层嵌入建模为图节点，用图卷积网络捕捉层间依赖来预测长度。这些方法的核心局限在于，点估计与自回归解码的随机本质存在内在冲突。

**随机调度.** TIE 本质上属于随机调度范畴：作业处理时间从已知分布随机抽取，而最短期望处理时间 (SEPT) 策略 (Weber, 1983) 最小化期望流时间。但随机调度理论难以直接用于 LLM 服务 (Mitzenmacher & Shahout, 2025)，因为：(i) 经典分析假设作业大小分布完全已知，而 LLM 输出长度必须从提示词预测；(ii) 多数排队理论结果基于 M/G/1 单服务器模型，现代 LLM 服务则使用连续批处理；(iii) 预测开销、KV 缓存竞争和抢占成本等实际因素进一步偏离理想理论设置。本文通过为各请求输出长度拟合分布，并纳入尾部风险感知调度，迈出了弥合差距的实际一步。

## 3. 预测不确定的输出长度

输出长度分布预测包含两个部分：(1) 选择并拟合合适分布以建模输出长度；(2) 训练预测器估计输出长度分布参数。

### 3.1. 通过分布拟合建模输出长度

LLM 推理本质上是随机的。每一步解码中，下一个输出 token 都从以前文为条件的概率分布采样。因此，相同输入提示词可能得到不同输出。

**分布选择.** 为研究相同提示词的输出长度分布，我们从 LMSYS-Chat-1M 采样 1K 个提示词，每个生成 100 个响应。观察到这些分布具有明显重尾特征：在 1K 个分布中，平均偏度 = 3.10，平均变异系数 (CV) = 1.09，其中 78.6% 的 CV > 1。最长的 10% 输出占总长度的 35.7%；平均 P90/P50 和 P99/P50 比值分别达到 4.62 和 10.77。

下面从理论上分析这种重尾行为。LLM 推理自回归生成 token，直到产生 EOS token。因此输出长度可以写为：

$$L = \min\{t \geq 1 : x_t = \text{EOS}\}. \quad (1)$$

一个关键观察是：不同生成轨迹的终止概率差异很大，其中一些轨迹终止率较低。例如，生成 JSON 对象时，模型在“{”和“}”之间维持很低的终止概率，以保证输出完整。为形式化描述这一观察，我们引入以下假设：

**假设 3.1.** 各生成轨迹的终止率服从一个密度为  $f$  的分布，满足  $f(p) \sim c \cdot p^{\alpha-1}$  as  $p \rightarrow 0^+$ ，其中常数  $\alpha, c > 0$ 。

**定理 3.2.** 在假设 3.1 下，输出长度的尾部概率呈幂律衰减：

$$P(L > n) \sim \frac{c \cdot \Gamma(\alpha)}{n^\alpha} \quad \text{as } n \rightarrow \infty. \quad (2)$$

<sup>1</sup><https://github.com/Hyzheng-code/TIE>

表 1. 常见重尾分布的拟合优度 (1,000 个提示词, 每个生成 100 次)。KS 通过率: 拟合通过 KS 检验 ( $p > 0.05$ ) 的提示词比例。

| 分布                    | 参数个数 | KS 通过率 |
|-----------------------|------|--------|
| Log-t                 | 3    | 93.1%  |
| Log-t ( $\nu = 3.5$ ) | 2    | 90.6%  |
| 对数正态                  | 2    | 60.3%  |
| Gamma 分布              | 2    | 32.0%  |
| Weibull 分布            | 2    | 19.0%  |
| 指数分布                  | 1    | 10.7%  |

详细证明见附录 A。定理 3.2 建立的幂律衰减被广泛认可为重尾的充分条件 (Clauset et al., 2009; Foss et al., 2011), 解释了经验分析中观察到的高偏度和极端分位数比值。

为识别合适的分布族, 我们对上述经验分布拟合若干常见重尾分布。通过 KS 检验评价拟合优度; 通常将  $p > 0.05$  视为拟合充分的指示 (Fisher, 1930; D’Agostino & Stephens, 1986; Alasmar et al., 2021)。

表 1 汇总各分布的参数数目及拟合表现。三参数 log-t 分布的通过率最高, 为 93.1%。由于 log-t 分布提供专门控制尾部行为的参数  $\nu$ , 我们进一步评估不同固定  $\nu$  值的两参数变体; 其中  $\nu = 3.5$  表现最佳, 通过率为 90.6% (详细结果见附录 D.3)。更多参数能带来更灵活的拟合, 但也增加预测模型复杂度, 提高训练和推理开销。为平衡效率与准确性, 后续实验采用固定  $\nu = 3.5$  的变体。第 6.4 节给出比较不同分布端到端表现的消融。

**分布拟合.** 我们重点使用 log-t 分布, 其定义为: 若  $Y \sim t(\nu)$  是自由度为  $\nu$  的标准 Student t 分布 (Student, 1908), 则  $X = \exp(\mu + \sigma Y)$  服从 log-t 分布, 记为  $X \sim \text{Log-t}(\mu, \sigma, \nu)$ 。根据定义, 标准 t 分布的概率密度函数 (PDF) 为

$$t_\nu(y) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi} \Gamma(\frac{\nu}{2})} \left(1 + \frac{y^2}{\nu}\right)^{-\frac{\nu+1}{2}} \quad (3)$$

相应地, log-t 分布的 PDF 为

$$f(x | \mu, \sigma, \nu) = \frac{1}{\sigma x} \cdot t_\nu\left(\frac{\ln x - \mu}{\sigma}\right) \quad (4)$$

我们通过最大似然估计 (MLE) 拟合分布。给定观测数据  $\{x_1, x_2, \dots, x_n\}$ , log-t 分布的对数似然函数为

$$\ell(\mu, \sigma, \nu) = \sum_{i=1}^n \left[ \ln t_\nu\left(\frac{\ln x_i - \mu}{\sigma}\right) - \ln \sigma - \ln x_i \right] \quad (5)$$

当  $\nu = 3.5$  时, 使用 L-BFGS-B 优化器联合估计  $\mu$  和  $\sigma$ 。优化目标为

$$\hat{\mu}, \hat{\sigma} = \arg \max_{\mu \in \mathbb{R}, \sigma > 0} \ell(\mu, \sigma, \nu = 3.5) \quad (6)$$

使用式 (6) 拟合每个提示词的观测输出长度分布, 得到分布参数。

### 3.2. 分布参数预测模型

在此基础上, 我们开发预测模型, 为每个到达提示词估计分布参数  $(\mu, \sigma)$ 。

**模型架构.** 如图 2 所示, 整体流程包含左侧预测器和右侧得分计算器。预测器有三个主要组件:

(1) **编码器:** 使用 DeBERTa-v3-base (86M 主干) 将提示词编码为上下文嵌入。选择它是因为其语义理解性能较好, 且微调和推理高效。

(2) **特征提取器:** 为捕捉多层次语义, 我们采用多池化融合策略, 结合 [CLS] token、均值池化和最大池化表示。其中 [CLS] 编码全局语义, 均值池化捕捉平均上下文信息, 最大池化突出显著特征。

(3) **参数预测器:** 为  $\mu$  和  $\sigma$  设计独立预测头。每个头都是具有三个隐藏层 (256、256、128) 和 dropout 正则化的 MLP。由于  $\sigma$  的经验分布右偏, 我们在变换空间中预测:  $\tilde{\sigma} = \log(1 + \sigma)$ 。

**训练策略.** 对  $\mu$  和  $\tilde{\sigma}$  进行 z-score 标准化, 并采用 MSE 损失和两阶段策略训练: 先优化全部参数, 再冻结编码器, 仅微调预测头。这保留预训练编码器的泛化能力。细节见代码。训练后模型对  $\mu$  和  $\sigma$  的  $R^2$  分别为 0.82 和 0.76。

## 4. 使用尾部膨胀期望调度

预测器建立后, 下面说明如何使用预测分布进行调度。

在作业执行时间服从已知分布的随机调度理论中, 最短期望处理时间 (SEPT) 是经典策略 (Weber, 1983)。但用于本场景时存在以下挑战:

1. 尽管 log-t 分布拟合合理, 但不能完全捕捉真实分布。
2. 分布参数由预测器估计, 难免存在误差。
3. 被预测为长请求的请求可能遭遇饥饿。

前两个问题说明, 预测输出长度和实际输出长度之间存在不可避免的偏差。尤其当真实长请求被误判为短请求时, 它会阻塞队列后续请求。LLM 输出本身具有重尾行为, 使问题更加严重。这些观察促使我们在调度中显式量化并管理尾部风险。

**风险敏感调度.** 我们采用条件风险价值 (CVaR) (Rockafellar et al., 2000) 量化请求的尾部风险。直观而言, CVaR 是以分布尾部为条件的期望。形式上, 对于随机变量  $X$  和置信水平  $\alpha \in (0, 1)$ :

$$\text{CVaR}_\alpha(X) = \mathbb{E}[X | X \geq \text{VaR}_\alpha(X)] \quad (7)$$

其中  $\text{VaR}_\alpha(X)$  (风险价值) 表示  $X$  的  $\alpha$  分位数。与




图 2. 整体评分流程。提示词前添加 CLS token 后由 DeBERTa 编码。多池化策略聚合 CLS token 表示、均值池化表示和最大池化表示。两个独立预测头（MLP）分别预测  $\hat{\mu}$  和  $\hat{\sigma}$ ，与固定  $\nu = 3.5$  一同构建 log-t 分布。最终得分由  $\mathbb{E}(\tilde{X})$  和 CVaR 计算。

P90 等单点指标相比，CVaR 能更好地刻画尾部行为。

我们使用 log-t 分布建模输出长度。实际 LLM 生成在达到  $\text{max\_tokens}$  限制后强制终止。为考虑这一点，在  $x_{\text{max}} = \text{max\_tokens}$  对预测分布进行右删失封顶，即  $\tilde{X} = \min(X, x_{\text{max}})$ 。对于  $X \sim \text{Log-t}(\mu, \sigma, \nu)$ ，定义部分期望函数：

$$\Psi(y) = \int_{-\infty}^y \exp(\mu + \sigma s) \cdot t_{\nu}(s) ds, \quad (8)$$

它表示区域  $\{Y \leq y\}$  对  $X$  期望的累计贡献。封顶后的期望及置信水平  $\alpha$  下的 CVaR 为（推导见附录 B）：

$$\mathbb{E}[\tilde{X}] = \Psi(y_{\text{max}}) + x_{\text{max}} \cdot [1 - T_{\nu}(y_{\text{max}})], \quad (9)$$

$$\text{CVaR}_{\alpha}[\tilde{X}] = \frac{\Psi(y_{\text{max}}) - \Psi(y_{\alpha}) + x_{\text{max}} \cdot [1 - T_{\nu}(y_{\text{max}})]}{1 - \alpha}, \quad (10)$$

其中  $y_{\text{max}} = (\ln x_{\text{max}} - \mu)/\sigma$ ， $y_{\alpha} = T_{\nu}^{-1}(\alpha)$  是  $\alpha$  分位数， $t_{\nu}(\cdot)$  是标准 t 分布的 PDF（见式 (3)）， $T_{\nu}(\cdot)$  是其 CDF。为提高调度效率，我们使用 10k 个样本的蒙特卡洛采样计算指标，而非数值积分。

对于每个请求，令  $\tilde{X}$  表示封顶后的预测输出长度分布，调度得分计算为

$$\text{Score} = \mathbb{E}[\tilde{X}] + \beta \cdot \text{CVaR}_{\alpha}[\tilde{X}] \quad (11)$$

设置  $\alpha = 0.9$ ，捕捉最高 10% 的尾部行为。系数  $\beta$  控制风险敏感度，并根据系统压力自适应调整。压力越大，调度长请求将使更多后续请求阻塞更久，因此需要更保守的策略，即更大的  $\beta$ 。具体地，使用等待队列长度  $L_q$  和配置的最大批大小  $B$  衡量压力，并为稳定性将  $\beta$  限制在  $[0.1, 0.5]$  内：

$$\beta = \min \left( 0.5, \max \left( 0.1, \frac{0.1 \cdot L_q}{B} \right) \right) \quad (12)$$

**防止饥饿。** 基于 SJF 的调度面临一个熟知挑战：高负载下，长请求易被短请求挤压而饥饿，等待时间过长，损害公平性。为缓解该问题，我们引入等待时间衰减，




图 3. 新请求的调度流程。实线箭头表示主流程，虚线箭头表示异步预测流程。

周期性将得分调整为  $\text{Score}' = \text{Score} \cdot \gamma^{t_w/\tau}$ ，其中  $t_w$  是请求等待时间， $\gamma \in (0, 1)$  是衰减因子， $\tau$  是衰减间隔。默认  $\gamma = 0.9$ ， $\tau = 30s$ 。指数衰减使久等请求逐渐获得优先权，防止饥饿，同时保留整体调度方案。

## 5. 实现与优化

我们在 vLLM 0.11.1 (Kwon et al., 2023) 上实现调度策略，并优化部署以提高预测和调度效率。

**挑战。** 现有预测调度方法通常使用同步预测 (Qiu et al., 2024; Shahout et al., 2025)：请求先预测，再按结果排序后入队。由于预测期间请求被阻塞，等待凑批会带来不可接受的延迟，因此通常逐个预测，放弃批处理吞吐优势。在普遍使用的连续批处理场景中，这尤其低效：(1) 低负载时，连续批处理允许新请求立即加入运行批，但同步预测引入不必要阻塞；(2) 高负载时，大量请求等待预测而累积，非批量预测不能高效识别最短请求。

为此，我们设计异步预测机制及动态批处理。

**异步预测。** 调度器解耦为主线程和预测线程。预测线程高效预测待处理请求，不阻塞请求入队或主线程处理。主线程则在运行批出现空位时，从等待队列选取请求填补。

如图 3 所示，调度器收到新请求后，将其加入以最小堆实现的等待队列，并以  $\text{max\_tokens}$  为初始得分 (1a)。




图 4. 8B 模型在真实工作负载 LMSYS-Chat-1M 上进行在线聊天服务时，各调度器的性能。

该初始得分让未预测请求位于底部，已预测请求先执行，从而防止未预测的长请求阻塞运行批。同时，请求被提交到预测队列 (①b)；后台预测线程异步批量处理请求 (②)。预测完成后，调度器计算得分，更新堆中对应请求的优先级 (③)，再重建堆，使最小值保持在堆顶 (④)。

该设计允许低负载下新请求直接运行，避免不必要的预测开销；也支持批量预测，提高吞吐量。

**动态批处理。** 为适应不同负载，预测线程采用动态批处理。请求可以短暂等待，以累积更大批次。超时 (3ms) 或请求数达到最大批大小 (32) 时，将其作为一个批次提交给预测器。

高负载下，该机制使等待请求迅速完成批量预测，从而快速识别长等待队列中的最短请求。

**复杂度。** 从等待队列读取最小元素需要  $O(1)$ ，插入、取出和优先级更新均需  $O(\log n)$ ，使调度器在高负载下仍能高效处理请求。

## 6. 实验评估

本节将 TIE 调度策略与现有先进 (SOTA) 非抢占方法比较，并通过参数调优和消融验证设计选择。

### 6.1. 实验设置

**测试平台。** 实验服务器配备  $8 \times$  NVIDIA A6000 (48 GB) GPU，通过 NVLink 互连，另有 128 个虚拟 CPU 核及 512 GB 内存。

**服务模型。** 主实验评估 Meta-Llama-3-8B-Instruct 和 Meta-Llama-3-70B-Instruct，均使用 FP16 精度。70B 模型采用 8 路张量并行。附录 D.1 还评估其他模型族的六个模型，包括三个混合专家 (MoE) 模型。

**工作负载和数据集。** 实验涵盖在线聊天服务和离线合成数据生成 (SDG)。使用三个数据集：LMSYS-Chat-1M (Zheng et al., 2024)、ShareGPT (RyokoAI, 2023) 和 Alpaca (Taori et al., 2023)。前两个包含用户与 LLM 聊天机器人的真实对话；Alpaca 是通过 GPT-3.5 的

self-instruct 生成的合成数据集。

**基线。** 评估：(1)FCFS, vLLM 默认策略；(2)SSJF (Qiu et al., 2024) 和 (3) LTR (Fu et al., 2024)，即第 1 节介绍的先进非抢占方法；(4) 上文的 TIE (本文)。细节见附录 C.1。

**训练数据。** 除特别说明外，所有方法训练数据均来自 LMSYS-Chat-1M，输出由 Meta-Llama-3-8B-Instruct 生成。各方法训练数据规模保持一致，共 900K 个样本：SSJF 和 LTR 使用前 900K 个样本；TIE 使用前 45K 个提示词，每个重复生成 20 次以拟合分布，重复次数在附录 D.2 调整。该配置保证相同训练数据规模。

### 6.2. 在线聊天服务

沿用既有工作 (Fu et al., 2024)，我们使用每 token 延迟 (PTLA) 和首 token 时间 (TTFT) 反映在线聊天体验。PTLA 衡量每个输出 token 的平均延迟；TTFT 衡量首个输出 token 前的等待时间。

**结果。** 图 4 展示 LMSYS-Chat-1M 与 8B 模型上各方法的表现。随着每秒请求数 (RPS) 增加，所有指标均上升，FCFS 上升最陡。SSJF 和 LTR 预测长度并排序，将每 token 延迟和 TTFT 分别最多降低  $2.05 \times$  和  $1.78 \times$ 。TIE 通过建模并预测输出长度分布，利用 LLM 输出的内在不确定性进一步改善。如图 4a，在 100 RPS 时，相对于 FCFS，TIE 将平均每 token 延迟降低  $4.73 \times$ ；相对于 SSJF 和 LTR 分别降低  $2.91 \times$  和  $2.31 \times$ 。TTFT 也出现类似结果。该改善来自全面捕捉可能输出长度及潜在风险的分布估计。

为评估对负载波动的适应能力，我们考察 RPS 从 30 快速增至 100 时平均每 token 延迟的增长。FCFS、SSJF、LTR 分别增长  $7.42 \times$ 、 $8.55 \times$ 、 $6.17 \times$ ，TIE 仅增长  $3.68 \times$ 。这源于风险自适应策略：队列请求累积时，TIE 采取更保守策略，降低潜在长请求的优先级，从而减少 HOL 阻塞风险。

**跨模型和跨数据集泛化。** 我们进一步评估泛化。所有预测器均用 8B 模型从 LMSYS-Chat-1M 生成的数据训练；测试 ShareGPT、Alpaca 和 70B 模型。结果汇总于表 2。

表 2. 请求速率为 100 RPS 时，调度策略跨数据集和模型的泛化表现。所有方法训练数据均由 8B 模型从 LMSYS-Chat-1M 生成。

| 测试数据集         | 测试模型规模 | 平均每 token 延迟 (秒/token) ↓ |      |      |      | P90 每 token 延迟 (秒/token) ↓ |      |      |      |
|---------------|--------|--------------------------|------|------|------|----------------------------|------|------|------|
|               |        | FCFS                     | SSJF | LTR  | TIE  | FCFS                       | SSJF | LTR  | TIE  |
| LMSYS-Chat-1M | 70B    | 9.08                     | 5.50 | 4.34 | 2.41 | 16.13                      | 8.24 | 7.03 | 4.05 |
| ShareGPT      | 8B     | 1.66                     | 0.95 | 0.86 | 0.57 | 3.27                       | 1.84 | 1.56 | 0.90 |
|               | 70B    | 4.36                     | 2.43 | 2.22 | 1.41 | 8.78                       | 4.90 | 3.78 | 2.22 |
| Alpaca        | 8B     | 1.45                     | 0.71 | 0.83 | 0.52 | 3.62                       | 1.47 | 1.76 | 0.93 |
|               | 70B    | 4.52                     | 2.06 | 2.36 | 1.54 | 11.36                      | 4.32 | 5.14 | 2.81 |

| 测试数据集         | 测试模型规模 | 平均 TTFT (秒) ↓ |        |        |        | P90 TTFT (秒) ↓ |        |        |        |
|---------------|--------|---------------|--------|--------|--------|----------------|--------|--------|--------|
|               |        | FCFS          | SSJF   | LTR    | TIE    | FCFS           | SSJF   | LTR    | TIE    |
| LMSYS-Chat-1M | 70B    | 319.51        | 273.30 | 252.20 | 204.03 | 618.21         | 551.15 | 507.35 | 475.10 |
| ShareGPT      | 8B     | 161.56        | 132.58 | 120.03 | 98.10  | 316.07         | 296.69 | 273.87 | 239.04 |
|               | 70B    | 417.28        | 342.45 | 346.50 | 288.79 | 807.27         | 744.59 | 696.75 | 660.28 |
| Alpaca        | 8B     | 83.65         | 62.93  | 65.33  | 54.18  | 159.72         | 140.80 | 142.17 | 123.02 |
|               | 70B    | 235.64        | 171.14 | 174.31 | 146.14 | 444.52         | 395.78 | 394.10 | 359.08 |

表 3. 调度器在 SDG 任务中跨训练数据集和测试模型规模的表现。使用 Alpaca 数据集评估。

| 训练数据集         | 测试模型规模 | 生成 3k 样本时间 (秒) ↓ |        |        |          | 3 分钟内吞吐量 ↑ |      |      |          |
|---------------|--------|------------------|--------|--------|----------|------------|------|------|----------|
|               |        | FCFS             | SSJF   | LTR    | TIE (本文) | FCFS       | SSJF | LTR  | TIE (本文) |
| LMSYS-Chat-1M | 8B     | 229.37           | 144.93 | 139.53 | 98.12    | 2292       | 3488 | 3672 | 4762     |
|               | 70B    | 559.30           | 324.52 | 316.98 | 246.10   | 861        | 1557 | 1895 | 2524     |
| Alpaca        | 8B     | 229.37           | 135.79 | 130.67 | 95.08    | 2292       | 3766 | 3663 | 4869     |
|               | 70B    | 559.30           | 311.06 | 314.36 | 240.19   | 861        | 1634 | 1708 | 2659     |

在 70B 模型的每 token 延迟上，TIE 相对于 FCFS 加速 3.77 $\times$ ，SSJF 和 LTR 分别为 1.65 $\times$  和 2.09 $\times$ 。在 ShareGPT 上，TIE 仍优于既有方法，相对于 FCFS 的加速为 2.91 $\times$  (8B) 和 3.09 $\times$  (70B)。Alpaca 上也观察到类似结果。

结果表明 TIE 能较好泛化至多种设置。这归因于分布建模避免对特定工作负载过拟合，以及风险自适应调度缓解预测误差。

### 6.3. 离线合成数据生成 (SDG)

高质量数据稀缺，使 SDG 成为重要 LLM 推理负载 (Chan et al., 2024)。SDG 通常偏好短响应，因为成本效益更好、多样性更大，也能缓解下游评估的长度偏差 (Singhal et al., 2024; Dubois et al., 2024)。这使 SDG 成为 SJF 策略的重要测试场景 (Fu et al., 2024)。Alpaca 是通过 self-instruct 生成的合成数据，自然可作为代表性 SDG 基准 (Taori et al., 2023)。

沿用既有工作 (Fu et al., 2024)，提交 10K 个提示词，并使用：(1) 生成 3K 样本所需时间，即 time@3K；(2) 3 分钟内生成样本数，即吞吐量。

**结果.** 表 3 显示，SJF 和 LTR 在两个指标上均胜过 FCFS，生成更快，TIE 进一步改善。在 time@3K 上，

TIE 相对于 FCFS、SSJF、LTR 分别加速约 2.34 $\times$ 、1.48 $\times$  和 1.42 $\times$ 。跨模型、跨数据集时，提升略减，但仍保持较强表现。结果验证了从分布和不确定性视角考虑输出长度的设计。

为解释改善，图 5 可视化各策略的调度模式。颜色表示请求集中程度。受篇幅限制，仅展示输出长度小于 512 token 的请求，超过全部请求的 90%。8B 和 70B 的完整图见附录 D.10。

FCFS 下，请求在各长度上近乎均匀分布。SSJF 和 LTR 通过预测长度优先处理短请求，使短请求聚集在左下方；但长输出的聚集较弱，说明它们难以排序长输出请求。原因是长请求（如“写一篇关于人工智能的文章”）比短请求（如“将‘谢谢’翻译为西班牙语”）本质上具有更高输出不确定性。TIE 显式建模长度分布并纳入不确定性，更准确描述可能长度。因此，即便长输出请求，其调度也显著更集中。这表明 TIE 能增强最短作业优先原则的效果。

### 6.4. 消融研究

我们逐一消融 TIE 组件，以评估贡献。

**分布族.** 第 3.1 节比较若干常见重尾分布的拟合表现，最终选择固定  $\nu = 3.5$  的 log-t。我们还对 KS 通过率




图 5. 8B 模型在 Alpaca 数据集上使用不同策略时，完成时间与输出长度的热力图。TIE 比 SSJF 和 LTR 更集中，表明其能够准确捕捉可能的输出长度。

表 4. 分布族和得分计算方式的消融。在线聊天实验使用 LMSYS-Chat-1M，离线 SDG 使用 Alpaca。全部实验使用 Meta-Llama-3-8B-Instruct。得分中的 CVaR 取  $\alpha = 0.9$ ， $\beta$  是自适应风险敏感系数。灰行是 TIE 默认配置，橙行是分布族消融，绿行是得分计算消融。

| 分布                  | 得分 =                                      | 每 token 延迟 (秒) ↓ |      | TTFT (秒) ↓ |        | 生成 3k<br>样本时间 (秒) ↓ | 3 分钟内<br>吞吐量 ↑ |
|---------------------|-------------------------------------------|------------------|------|------------|--------|---------------------|----------------|
|                     |                                           | 平均               | P90  | 平均         | P90    |                     |                |
| log-t ( $\nu=3.5$ ) | $\mathbb{E}[X] + \beta \cdot \text{CVaR}$ | 0.67             | 0.96 | 48.23      | 131.13 | 98.12               | 4762           |
| log-t (动态 $\nu$ )   | $\mathbb{E}[X] + \beta \cdot \text{CVaR}$ | 0.69             | 1.02 | 47.76      | 132.40 | 97.70               | 4709           |
| 对数正态                | $\mathbb{E}[X] + \beta \cdot \text{CVaR}$ | 1.63             | 3.37 | 70.91      | 174.88 | 142.21              | 3584           |
| log-t ( $\nu=3.5$ ) | $\mathbb{E}[X]$ (即 SEPT 调度)               | 0.75             | 1.21 | 52.26      | 145.03 | 108.51              | 4257           |
| log-t ( $\nu=3.5$ ) | $\mathbb{E}[X] + 0.1 \cdot \text{CVaR}$   | 0.72             | 1.15 | 50.07      | 141.77 | 104.76              | 4391           |
| log-t ( $\nu=3.5$ ) | $\mathbb{E}[X] + 0.3 \cdot \text{CVaR}$   | 0.71             | 1.18 | 49.33      | 139.65 | 105.04              | 4422           |

> 50% 的其他分布族训练模型并调度。表 4 给出在线和离线结果。相比 TIE，对数正态拟合较差 (60.3% 对 90.6%)，导致调度性能下降，说明拟合质量直接影响分布建模准确性和调度效果。动态  $\nu$  的 log-t 表现与 TIE 相近；考虑复杂度和效率，采用固定  $\nu$ 。

**得分计算.** 式 11 纳入期望、CVaR 和自适应风险敏感系数  $\beta$ 。表 4 还评估其他计算方式。仅用期望 (即 SEPT) 表现合理；加入 CVaR 进一步改善，采用自适应  $\beta$  时提升最明显。

我们还在不同 RPS 下评估  $\beta$ ，见附录 D.7。最优固定  $\beta$  随 RPS 改变，而真实工作负载通常具有波动 RPS，因此需要自适应  $\beta$ 。

**调度开销.** 在 LMSYS-Chat-1M、8B 模型、100 RPS 的在线聊天实验中，预测和调度平均延迟为每请求 4.26 ms，平均 TTFT 为 48.23 s。相比 FCFS 的平均 TTFT 127.55 s，TIE 开销相对于性能收益可忽略。

## 7. 讨论

**与学习增强算法的联系.** TIE 用预测器估计参数、构建分布并调度，自然属于学习增强算法框架 (Lykouris & Vassilvitskii, 2021; Purohit et al., 2018; Mitzenmacher & Vassilvitskii, 2022)。其核心设计挑战是平衡一致性 (预测准确时表现好) 和稳健性 (预测错误时平缓退化)。

调度得分 (式 11) 对应这两方面： $\mathbb{E}[\tilde{X}]$  是信任预测的一致性分量，反映预测准确时预计请求所需工作量； $\text{CVaR}_\alpha[\tilde{X}]$  通过防范预测错误或内在随机性导致的尾部结果体现稳健性。自适应系数  $\beta$  (式 12) 控制权衡：低压力时  $\beta$  较小，偏重  $\mathbb{E}[\tilde{X}]$  以获得一致性；压力增大时  $\beta$  增加，偏重 CVaR 以提高稳健性。消融 (表 4) 表明，该设计优于纯 SEPT (仅一致性) 和固定  $\beta$  (静态权衡)，说明学习增强算法的一致性—稳健性原则能有效用于 LLM 推理调度。

**局限.** TIE 的实际局限是训练数据需求。点估计预测器可直接用 LLM 服务生产日志训练，而 TIE 需要每个提示词多次生成，以拟合长度分布。附录 D.5 评估训练规模影响。泛化能力部分缓解该问题，但降低训练数据需求，例如通过少样本学习，仍是重要未来方向。

## 8. 结论

我们提出不确定性感知的 LLM 推理调度策略 TIE。采用 log-t 分布建模请求输出长度的重尾分布，并引入 CVaR 和风险自适应调度处理尾部风险。实验表明，TIE 在在线和离线场景均显著优于 FCFS 及现有先进方法，并可较好泛化到不同数据集和模型。

## 致谢

本工作由中国国家自然科学基金 (NO. 62472327、No. 62272353)、湖北省重点研发计划 (No. 2023BAB077)、四川省医学影像临床研究中心 (YXYX2402) 和腾讯研究基金资助。感谢匿名审稿人的建设性反馈, 这些反馈帮助改进了本论文。

## 影响声明

TIE 提高 LLM 推理效率和服务质量, 其分布建模视角还可能有益于推理调度之外的相关领域。作为基础设施层面的优化, TIE 不会为底层 LLM 引入新能力。

## 参考文献

- Alasmar, M., Clegg, R., Zakhleniuk, N., and Parisi, G. Internet traffic volumes are not Gaussian—they are log-normal: An 18-year longitudinal study with implications for modelling and prediction. *IEEE/ACM Transactions on Networking*, 29(3):1266–1279, 2021.
- Anthropic. Introducing Claude. <https://www.anthropic.com/news/introducing-claude>, 2023.
- Cassidy, D. T., Hamp, M. J., and Ouyed, R. Pricing European options with a log Student’s t-distribution: A Gosset formula. *Physica A: Statistical Mechanics and its Applications*, 389(24):5736–5748, 2010.
- Chan, Y.-C., Pu, G., Shanker, A., Suresh, P., Jenks, P., Heyer, J., and Denton, S. M. Balancing cost and effectiveness of synthetic data generation strategies for LLMs. In *NeurIPS Workshop on Fine-Tuning in Modern Machine Learning: Principles and Scalability*, 2024.
- Chatterji, A., Cunningham, T., Deming, D. J., Hitzig, Z., Ong, C., Shan, C. Y., and Wadman, K. How people use ChatGPT. Technical report, National Bureau of Economic Research, 2025.
- Chen, H., Wang, Y., Han, K., Li, D., Li, L., Bi, Z., Li, J., Wang, H., Mi, F., Zhu, M., Wang, B., Song, K., Fu, Y., He, X., Luo, Y., Zhu, C., He, Q., Wu, X., He, W., Hu, H., Tang, Y., Tao, D., Chen, X., and Wang, Y. Pangu Embedded: An efficient dual-system LLM reasoner with metacognition, 2025a. URL <https://arxiv.org/abs/2505.22375>.
- Chen, Z., Ye, Y., and Zhou, Z. Adaptively robust LLM inference optimization under prediction uncertainty. *arXiv preprint arXiv:2508.14544*, 2025b.
- Choi, S., Goo, J., Jeon, E., Yang, M., and Jang, M. ELIS: Efficient LLM iterative scheduling system with response length predictor, 2025. URL <https://arxiv.org/abs/2505.09142>.
- Clauset, A., Shalizi, C. R., and Newman, M. E. Power-law distributions in empirical data. *SIAM review*, 51(4):661–703, 2009.
- D’Agostino, R. B. and Stephens, M. A. Goodness-of-fit techniques, 1986.
- Dubois, Y., Liang, P., and Hashimoto, T. Length-Controlled AlpacaEval: A simple debiasing of automatic evaluators. In *First Conference on Language Modeling*, 2024. URL <https://openreview.net/forum?id=CybBmzWBX0>.
- Fisher, R. A. *Statistical methods for research workers*. Oliver and Boyd, 1930.
- Foss, S., Korshunov, D., Zachary, S., et al. *An introduction to heavy-tailed and subexponential distributions*, volume 6. Springer, 2011.
- Fu, Y., Zhu, S., Su, R., Qiao, A., Stoica, I., and Zhang, H. Efficient LLM scheduling by learning to rank. *Advances in Neural Information Processing Systems*, 37:59006–59029, 2024.
- Google DeepMind. Introducing Gemini: Our largest and most capable AI model. <https://blog.google/technology/ai/google-gemini-ai/>, 2023.
- Guo, D., Yang, D., Zhang, H., Song, J., Wang, P., Zhu, Q., Xu, R., Zhang, R., Ma, S., Bi, X., et al. DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. *Nature*, 645(8081): 633–638, 2025.
- He, P., Liu, X., Gao, J., and Chen, W. DeBERTa: Decoding-enhanced BERT with disentangled attention. In *International Conference on Learning Representations*, 2021.
- He, P., Gao, J., and Chen, W. DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training with gradient-disentangled embedding sharing. In *The Eleventh International Conference on Learning Representations*, 2023.
- Horton, M., Cao, Q., Sun, C., Jin, Y., Mehta, S., Rastegari, M., and Nabi, M. KV prediction for improved time to first token. In *First Workshop on Scalable Optimization for Efficient and Adaptive Foundation Models*, 2025. URL <https://openreview.net/forum?id=Bnilyw49vY>.

- Hu, C., Bao, W., Wang, D., and Liu, F. Dynamic adaptive DNN surgery for inference acceleration on the edge. In *IEEE INFOCOM 2019-IEEE Conference on Computer Communications*, pp. 1423–1431. IEEE, 2019.
- Jiang, J., Cui, B., Zhang, C., and Yu, L. Heterogeneity-aware distributed parameter servers. In *Proceedings of the 2017 ACM International Conference on Management of Data*, pp. 463–478, 2017.
- Jiang, J., Gan, S., Liu, Y., Wang, F., Alonso, G., Klimovic, A., Singla, A., Wu, W., and Zhang, C. Towards demystifying serverless machine learning training. In *Proceedings of the 2021 international conference on management of data*, pp. 857–871, 2021.
- Jin, Y., Wu, C.-F., Brooks, D., and Wei, G.-Y. S<sup>3</sup>: Increasing GPU utilization during generative inference for higher throughput. *Advances in Neural Information Processing Systems*, 36:18015–18027, 2023.
- Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C. H., Gonzalez, J., Zhang, H., and Stoica, I. Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th symposium on operating systems principles*, pp. 611–626, 2023.
- Lykouris, T. and Vassilvitskii, S. Competitive caching with machine learned advice. *Journal of the ACM (JACM)*, 68(4):1–25, 2021.
- Massey Jr, F. J. The Kolmogorov-Smirnov test for goodness of fit. *Journal of the American Statistical Association*, 46(253):68–78, 1951.
- Mitzenmacher, M. and Shahout, R. Queueing, predictions, and large language models: Challenges and open problems. *Stochastic Systems*, 15(3):195–219, 2025.
- Mitzenmacher, M. and Vassilvitskii, S. Algorithms with predictions. *Communications of the ACM*, 65(7):33–35, 2022.
- Nguyen, M., Baker, A., Neo, C., Roush, A., Kirsch, A., and Shwartz-Ziv, R. Turning up the heat: Min-p sampling for creative and coherent LLM outputs. In *International Conference on Learning Representations*, volume 2025, pp. 70333–70366, 2025.
- OpenAI. Introducing ChatGPT. <https://openai.com/blog/chatgpt>, 2022.
- OpenAI. gpt-oss-120b & gpt-oss-20b model card, 2025. URL <https://arxiv.org/abs/2508.10925>.
- Piotrowski, G., Bystróński, M., Hołysz, M., Binkowski, J., Chodak, G., and Kajdanowicz, T. J. When will the tokens end? graph-based forecasting for LLMs output length. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 4: Student Research Workshop)*, pp. 843–848, 2025.
- Purohit, M., Svitkina, Z., and Kumar, R. Improving online algorithms via ML predictions. *Advances in Neural Information Processing Systems*, 31, 2018.
- Qiu, H., Mao, W., Patke, A., Cui, S., Jha, S., Wang, C., Franke, H., Kalbarczyk, Z. T., Basar, T., and Iyer, R. K. Efficient interactive LLM serving with proxy model-based sequence length prediction. In *International Conference on Architectural Support for Programming Languages and Operating Systems*, 2024.
- Rockafellar, R. T., Uryasev, S., et al. Optimization of conditional value-at-risk. *Journal of risk*, 2:21–42, 2000.
- RyokoAI. ShareGPT52K. <https://huggingface.co/datasets/RyokoAI/ShareGPT52K>, 2023.
- Shahout, R., Malach, E., Liu, C., Jiang, W., Yu, M., and Mitzenmacher, M. Don’t stop me now: Embedding based scheduling for LLMs. In *The Thirteenth International Conference on Learning Representations*, 2025.
- Singhal, P., Goyal, T., Xu, J., and Durrett, G. A long way to go: Investigating length correlations in RLHF. In *First Conference on Language Modeling*, 2024.
- Student. The probable error of a mean. *Biometrika*, pp. 1–25, 1908.
- Taori, R., Gulrajani, I., Zhang, T., Dubois, Y., Li, X., Guestrin, C., Liang, P., and Hashimoto, T. B. Stanford Alpaca: An instruction-following LLaMA model. [https://github.com/tatsu-lab/stanford\\_alpaca](https://github.com/tatsu-lab/stanford_alpaca), 2023.
- Team, Q. Qwen3 technical report, 2025. URL <https://arxiv.org/abs/2505.09388>.
- vLLM. vLLM documentation: Optimization and tuning. <https://docs.vllm.ai/en/stable/configuration/optimization/>, 2025. Accessed: 2025-01-16.
- Weber, R. R. Scheduling stochastic jobs on parallel machines to minimize makespan or flowtime. In *Applied Probability—Computer Science: The Interface*, pp. 327–344. Springer, 1983.

- Wu, B., Zhong, Y., Zhang, Z., Liu, S., Liu, F., Sun, Y., Huang, G., Liu, X., and Jin, X. Fast distributed inference serving for large language models, 2024. URL <https://arxiv.org/abs/2305.05920>.
- Yang, A., Yu, B., Li, C., Liu, D., Huang, F., Huang, H., Jiang, J., Tu, J., Zhang, J., Zhou, J., Lin, J., Dang, K., Yang, K., Yu, L., Li, M., Sun, M., Zhu, Q., Men, R., He, T., Xu, W., Yin, W., Yu, W., Qiu, X., Ren, X., Yang, X., Li, Y., Xu, Z., and Zhang, Z. Qwen2.5-1M technical report. *arXiv preprint arXiv:2501.15383*, 2025.
- Yu, G.-I., Jeong, J. S., Kim, G.-W., Kim, S., and Chun, B.-G. Orca: A distributed serving system for transformer-based generative models. In *16th USENIX Symposium on Operating Systems Design and Implementation*, pp. 521–538, 2022.
- Zheng, L., Chiang, W.-L., Sheng, Y., Li, T., Zhuang, S., Wu, Z., Zhuang, Y., Li, Z., Lin, Z., Xing, E., Gonzalez, J. E., Stoica, I., and Zhang, H. LMSYS-Chat-1M: A large-scale real-world LLM conversation dataset. In *The Twelfth International Conference on Learning Representations*, 2024.
- Zheng, Z., Ren, X., Xue, F., Luo, Y., Jiang, X., and You, Y. Response length perception and sequence scheduling: An LLM-empowered LLM inference pipeline. *Advances in Neural Information Processing Systems*, 36:65517–65530, 2023.
- Zhong, Y., Liu, S., Chen, J., Hu, J., Zhu, Y., Liu, X., Jin, X., and Zhang, H. DistServe: disaggregating prefill and decoding for goodput-optimized large language model serving. In *Proceedings of the 18th USENIX Conference on Operating Systems Design and Implementation*, USA, 2024. USENIX Association. ISBN 978-1-939133-40-3.

## A. 重尾输出长度分布的理论分析

本附录给出支持正文定理 3.2 的理论分析。我们证明，在假设 3.1 下，输出长度分布具有重尾特征，尾部呈幂律衰减。

### A.1. 问题设置

考虑自回归语言模型的文本生成。给定输入提示词，模型逐一采样 token  $x_1, x_2, \dots$ ，直到产生 EOS。沿用正文，输出长度定义为

$$L = \min\{t \geq 1 : x_t = \text{EOS}\}. \quad (13)$$

令  $p_t = P(x_t = \text{EOS} \mid x_{<t})$  表示步骤  $t$  生成 EOS 的概率。由于此前上下文  $x_{<t}$  来自随机采样， $p_t$  本身也是依赖生成轨迹的随机变量。

**引理 A.1** (尾部概率表达式). 输出长度  $L$  的尾部概率满足

$$P(L > n) = \mathbb{E} \left[ \prod_{t=1}^n (1 - p_t) \right]. \quad (14)$$

*证明.* 事件  $\{L > n\}$  当且仅当前  $1, 2, \dots, n$  步均未生成 EOS 时发生。由条件概率链式法则，

$$P(L > n) = P(x_1 \neq \text{EOS}, \dots, x_n \neq \text{EOS}) = \mathbb{E} \left[ \prod_{t=1}^n (1 - p_t) \right], \quad (15)$$

其中期望针对全部随机生成轨迹计算。  $\square$

为方便起见，重述正文假设 3.1。

**假设 A.2** (重述假设 3.1). 各生成轨迹的终止率服从一个密度为  $f$  的分布，当  $p \rightarrow 0^+$  时满足  $f(p) \sim c \cdot p^{\alpha-1}$ ，其中常数  $\alpha, c > 0$ 。

### A.2. 主定理的证明

为连接引理 A.1 与假设 A.2，引入生成轨迹的**有效终止率**：

$$\tilde{p}_n = 1 - \left( \prod_{t=1}^n (1 - p_t) \right)^{1/n}, \quad (16)$$

它表示前  $n$  步终止概率的几何平均。该量捕捉轨迹的整体终止倾向：生成冗长内容，如详细解释或结构化输出的轨迹，往往具有较低  $\tilde{p}_n$ ；生成简短响应的轨迹则具有较高  $\tilde{p}_n$ 。

实际上，由于自回归性质使每个  $p_t$  依赖此前上下文， $\tilde{p}_n$  只能在生成完成后回顾计算。但轨迹“类型”，即冗长还是简短，很大程度由早期采样决定。这促成假设 A.2：每条轨迹在生成开始时可由固定终止率  $\tilde{p}$  刻画。

在该假设下，式 (14) 的尾部概率简化为混合模型：

$$P(L > n) = \mathbb{E} [(1 - \tilde{p})^n] = \int_0^1 (1 - p)^n f(p) dp. \quad (17)$$

下面证明定理 3.2，使用假设 A.2。

**定理 3.2 的证明.** 根据假设 A.2，密度  $f$  在  $p \rightarrow 0^+$  时满足  $f(p) \sim c \cdot p^{\alpha-1}$ 。

固定  $\delta \in (0, 1)$ ，将式 (17) 中的积分分解为

$$P(L > n) = \underbrace{\int_0^\delta (1 - p)^n f(p) dp}_{I_1(n)} + \underbrace{\int_\delta^1 (1 - p)^n f(p) dp}_{I_2(n)}. \quad (18)$$

对  $p \in [\delta, 1]$ , 有  $(1-p)^n \leq (1-\delta)^n$ , 因此

$$I_2(n) \leq (1-\delta)^n \int_{\delta}^1 f(p) dp \leq (1-\delta)^n = O((1-\delta)^n) = o(n^{-\alpha}). \quad (19)$$

所以  $I_2(n)$  指数衰减, 相比任意多项式衰减都可忽略。

对  $I_1(n)$ , 代换  $u = np$  得

$$I_1(n) = \frac{1}{n} \int_0^{n\delta} \left(1 - \frac{u}{n}\right)^n f\left(\frac{u}{n}\right) du. \quad (20)$$

定义  $h_n(u) = n^\alpha \cdot (1-u/n)^n \cdot f(u/n) / n \cdot \mathbf{1}_{[0, n\delta]}(u)$ 。由假设 A.2, 存在  $M > 0$ , 使所有  $p \in (0, \delta)$  满足  $f(p) \leq Mp^{\alpha-1}$ 。由于  $\delta < 1$ , 积分域内  $u \leq n\delta < n$ , 可用标准不等式  $(1-u/n)^n \leq e^{-u}$ , 得到

$$|h_n(u)| \leq M \cdot u^{\alpha-1} e^{-u}, \quad (21)$$

右侧在  $[0, \infty)$  可积, 积分为  $M\Gamma(\alpha)$ 。此外, 对任意固定  $u > 0$ , 当  $n \rightarrow \infty$  时,

$$h_n(u) \rightarrow c \cdot u^{\alpha-1} e^{-u}. \quad (22)$$

由控制收敛定理,

$$\lim_{n \rightarrow \infty} n^\alpha I_1(n) = \int_0^\infty c \cdot u^{\alpha-1} e^{-u} du = c \cdot \Gamma(\alpha). \quad (23)$$

结合以上结果得

$$P(L > n) = I_1(n) + I_2(n) \sim \frac{c \cdot \Gamma(\alpha)}{n^\alpha} \quad \text{as } n \rightarrow \infty. \quad (24)$$

□

### A.3. 对重尾性质的意义

上述幂律尾部衰减具有重要含义。对任意  $\lambda > 0$ ,

$$\lim_{n \rightarrow \infty} e^{\lambda n} P(L > n) = \lim_{n \rightarrow \infty} \frac{c \cdot \Gamma(\alpha) \cdot e^{\lambda n}}{n^\alpha} = \infty. \quad (25)$$

这是重尾分布的标准刻画 (Clauset et al., 2009; Foss et al., 2011), 意味着长输出以不可忽略的概率出现, 解释了经验分析 (第 3.1 节) 中观察到的高偏度、大变异系数和异常长输出频繁出现。

注记 A.3 (假设 3.1 和假设 A.2 的解释). 当  $p \rightarrow 0^+$  时, 条件  $f(p) \sim c \cdot p^{\alpha-1}$ , 等价于  $F(p) \sim \frac{c}{\alpha} p^\alpha$ , 刻画非忽略比例的生成轨迹持续具有低终止率的情形。这自然出现在若干实际场景。例如, 生成 JSON 或代码时, 模型必须在终止前完成语法结构, 如匹配花括号或圆括号, 使轨迹在较长区间内具有接近零的终止概率。类似地, 当模型决定生成详细解释或长篇响应时, 在内容完整前保持较低终止概率。如果小终止率  $p$  下这类轨迹的概率质量正比于  $p^\alpha$ , 就会出现定理 3.2 描述的重尾行为。

## B. 封顶删失 log-t 分布的推导

令  $Y \sim t(\nu)$  为自由度  $\nu$  的标准  $t$  分布随机变量。定义随机变量

$$X = \exp(\mu + \sigma Y), \quad (26)$$

它服从 log- $t$  分布, 记为  $X \sim \text{Log-}t(\mu, \sigma, \nu)$ , 其中  $\sigma > 0$  是尺度参数。

标准  $t$  分布的 PDF 为

$$t_\nu(y) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi} \Gamma(\frac{\nu}{2})} \left(1 + \frac{y^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \quad (27)$$

CDF 记为  $T_\nu(y)$ 。作变量代换  $x = \exp(\mu + \sigma y)$ , 得到 log- $t$  的 PDF:

$$f(x \mid \mu, \sigma, \nu) = \frac{1}{\sigma x} \cdot t_\nu\left(\frac{\ln x - \mu}{\sigma}\right), \quad x > 0. \quad (28)$$

定义封顶删失随机变量  $\tilde{X} = \min(X, x_{\max})$ , 并令

$$y_{\max} = \frac{\ln x_{\max} - \mu}{\sigma}. \quad (29)$$

为简化后续推导, 引入部分期望函数:

$$\Psi(y) = \int_{-\infty}^y \exp(\mu + \sigma s) \cdot t_{\nu}(s) ds. \quad (30)$$

该函数有自然概率解释:  $\Psi(y) = \mathbb{E}[X \cdot \mathbf{1}_{\{Y \leq y\}}]$  是事件  $\{Y \leq y\}$  对  $X$  期望的贡献。

LLM 推理中, `max_tokens` 为生成长度设置上限。因此, 在  $x_{\max} = \text{max\_tokens}$  封顶, 即  $\tilde{X} = \min(X, x_{\max})$ , 并计算总是有限的期望  $\mathbb{E}[\tilde{X}]$ 。这一处理是必要的, 因为未封顶的  $\log\text{-}t$  期望  $\mathbb{E}[X]$  不存在: 由于重尾, Student  $t$  的矩母函数对任意  $\sigma > 0$  都为无穷。

**$\Psi(y)$  的数值计算。**  $\Psi(y)$  没有闭式解, 因此使用蒙特卡洛采样高效计算。从标准  $t$  分布抽取  $N = 10,000$  个样本  $\{Y_i\}_{i=1}^N$ , 近似为

$$\Psi(y) \approx \frac{1}{N} \sum_{i=1}^N \exp(\mu + \sigma Y_i) \cdot \mathbf{1}_{\{Y_i \leq y\}}. \quad (31)$$

### B.1. 封顶后的期望

$\tilde{X}$  的期望可以分为两项:

$$\mathbb{E}[\tilde{X}] = \underbrace{\int_0^{x_{\max}} x \cdot f(x) dx}_{I_1} + \underbrace{x_{\max} \cdot \mathbb{P}(X > x_{\max})}_{I_2}. \quad (32)$$

**$I_1$  的推导。** 代入 PDF  $f(x) = \frac{1}{\sigma x} \cdot t_{\nu}\left(\frac{\ln x - \mu}{\sigma}\right)$ , 令  $y = (\ln x - \mu)/\sigma$ , 则  $x = \exp(\mu + \sigma y)$ ,  $dx = \sigma \exp(\mu + \sigma y) dy$ 。积分范围从  $x \in (0, x_{\max}]$  变为  $y \in (-\infty, y_{\max}]$ , 得到

$$\begin{aligned} I_1 &= \int_0^{x_{\max}} x \cdot \frac{1}{\sigma x} \cdot t_{\nu}\left(\frac{\ln x - \mu}{\sigma}\right) dx \\ &= \frac{1}{\sigma} \int_0^{x_{\max}} t_{\nu}\left(\frac{\ln x - \mu}{\sigma}\right) dx \\ &= \frac{1}{\sigma} \int_{-\infty}^{y_{\max}} t_{\nu}(y) \cdot \sigma \exp(\mu + \sigma y) dy \\ &= \int_{-\infty}^{y_{\max}} \exp(\mu + \sigma y) \cdot t_{\nu}(y) dy = \Psi(y_{\max}). \end{aligned} \quad (33)$$

**$I_2$  的推导。** 因  $X = \exp(\mu + \sigma Y)$ ,  $X \leq x_{\max}$  当且仅当  $Y \leq y_{\max}$ 。因此  $\mathbb{P}(X \leq x_{\max}) = T_{\nu}(y_{\max})$ , 且

$$I_2 = x_{\max} \cdot [1 - T_{\nu}(y_{\max})]. \quad (34)$$

结合以上结果得

$$\mathbb{E}[\tilde{X}] = \Psi(y_{\max}) + x_{\max} \cdot [1 - T_{\nu}(y_{\max})]. \quad (35)$$

这给出了第 (9) 式, 即第 4 节的结果。

### B.2. 封顶后的条件风险价值

CVaR 定义为 VaR 阈值以上的条件期望:

$$\text{CVaR}_{\alpha}(X) = \mathbb{E}[X \mid X \geq \text{VaR}_{\alpha}(X)], \quad (36)$$

其中  $\text{VaR}_{\alpha}(X) = F^{-1}(\alpha)$  是  $\alpha$  分位数。

**情形 1:**  $\alpha \geq T_\nu(y_{\max})$ 。此时  $\tilde{X}$  的  $\alpha$  分位数等于封顶点, 即  $\text{VaR}_\alpha(\tilde{X}) = x_{\max}$ , 且  $\mathbb{P}(\tilde{X} > x_{\max}) = 0$ 。由于条件事件概率为零, 条件期望在标准意义下没有良好定义。遵循风险管理文献的惯例, 定义

$$\text{CVaR}_\alpha(\tilde{X}) = x_{\max}. \quad (37)$$

**情形 2:**  $\alpha < T_\nu(y_{\max})$ 。封顶分布  $\tilde{X}$  的 VaR 为

$$v_\alpha \triangleq \text{VaR}_\alpha(\tilde{X}) = \exp(\mu + \sigma y_\alpha), \quad \text{where } y_\alpha = T_\nu^{-1}(\alpha). \quad (38)$$

由条件期望定义,

$$\text{CVaR}_\alpha(\tilde{X}) = \frac{\mathbb{E}[\tilde{X} \cdot \mathbf{1}_{\{\tilde{X} \geq v_\alpha\}}]}{\mathbb{P}(\tilde{X} \geq v_\alpha)}. \quad (39)$$

由于  $v_\alpha < x_{\max}$ , 分母等于  $1 - \alpha$ 。对分子, 事件  $\{\tilde{X} \geq v_\alpha\}$  包含两种情形: (i)  $v_\alpha \leq X < x_{\max}$ , 此时  $\tilde{X} = X$ ; (ii)  $X \geq x_{\max}$ , 此时  $\tilde{X} = x_{\max}$ 。因此

$$\mathbb{E}[\tilde{X} \cdot \mathbf{1}_{\{\tilde{X} \geq v_\alpha\}}] = \underbrace{\int_{v_\alpha}^{x_{\max}} x \cdot f_X(x) dx}_{J_1} + \underbrace{x_{\max} \cdot \mathbb{P}(X \geq x_{\max})}_{J_2}. \quad (40)$$

使用第 B.1 节的同一代换, 得到

$$J_1 = \int_{y_\alpha}^{y_{\max}} \exp(\mu + \sigma y) \cdot t_\nu(y) dy = \Psi(y_{\max}) - \Psi(y_\alpha), \quad J_2 = x_{\max} \cdot [1 - T_\nu(y_{\max})]. \quad (41)$$

结合以上结果,

$$\text{CVaR}_\alpha(\tilde{X}) = \frac{1}{1 - \alpha} [\Psi(y_{\max}) - \Psi(y_\alpha) + x_{\max} \cdot [1 - T_\nu(y_{\max})]]. \quad (42)$$

这给出了第 (10) 式, 即第 4 节的结果。

## C. 实验细节

### C.1. 基线细节

评估中比较的基线调度策略细节如下:

- **FCFS (先到先服务):** vLLM 等系统的默认策略, 严格按到达顺序处理请求。虽可保证公平性, 但存在队首阻塞: 长请求延迟后续短请求。
- **SSJF (推测最短作业优先) (Qiu et al., 2024):** 使用微调 BERT 等轻量代理模型预测输出长度, 以实现 SJF。在 [CLS] token 表示上使用回归头, 优先短请求以缓解 HOL 阻塞。
- **LTR (学习排序) (Fu et al., 2024):** 根据相对生成长度而非精确点估计优化请求顺序。用 ListMLE 损失训练 OPT-125M 等辅助预测器, 预测近似理想 SJF 顺序的排序得分, 并用 Kendall Tau 评估排序质量。

### C.2. 数据集细节

使用三个不同数据集, 在真实对话和合成数据等多类工作负载上评估性能:

- **LMSYS-Chat-1M (Zheng et al., 2024):** 从 Chatbot Arena 收集的大规模真实 LLM 对话数据集, 含约一百万段涉及超过 25 个 LLM 的对话。它覆盖广泛提示词及不同响应长度, 代表开放域聊天流量。
- **ShareGPT (RyokoAI, 2023):** 用户分享与 ChatGPT 交互的真实对话, 反映意图和结构多样的现实查询, 广泛用于 LLM 性能基准。




图 6. 不同数据集的提示词长度分布（用 Meta-Llama-3-8B-Instruct 分词），以及不同模型的输出长度分布。

- **Alpaca (Taori et al., 2023)**: 使用 GPT-3.5 和 Self-Instruct 框架生成的合成数据，包含 52,000 个覆盖广泛任务的指令跟随样本。其合成性质和多样性使其成为代表性 SDG 基准。

图 6 展示这些数据集的提示词长度及 Meta-Llama-3-8B-Instruct、Meta-Llama-3-70B-Instruct 的输出长度分布，每个数据集 10K 个样本。

三个数据集的提示词长度都右偏且有长尾。LMSYS-Chat-1M 和 ShareGPT 相似，均值约为中位数三倍，分别为 65.36 对 23、56.12 对 21，表明存在少数异常长提示词。Alpaca 提示词更短、更集中，均值和中位数接近，为 13.25 对 13。这是因为 Alpaca 包含简洁指令任务，而其他两个包含真实用户查询。

输出长度方面，所有数据集都明显右偏且重尾，均值总大于中位数。70B 在各数据集通常比 8B 输出略长，LMSYS-Chat-1M 差异最明显，均值为 203.01 对 177.19。三者中 ShareGPT 输出最长，Alpaca 最短。

这些观察表明 SDG 和聊天负载本质不同，需要分别评估调度。它们也突出关键挑战：输出长度的高方差和重尾使少量长请求阻塞后续请求，显著损害吞吐量和尾延迟 (Jiang et al., 2017)。因此，需要准确识别此类请求的调

表 5. 聊天工作负载中不同模型上的调度性能比较。

| 模型                           | 数据集           | 平均 PTLA (秒/token) ↓ |      |      |      | 平均 TTFT (秒) ↓ |         |         |        |
|------------------------------|---------------|---------------------|------|------|------|---------------|---------|---------|--------|
|                              |               | FCFS                | SSJF | LTR  | TIE  | FCFS          | SSJF    | LTR     | TIE    |
| GPT-oss-20B                  | LMSYS-Chat-1M | 11.55               | 6.77 | 4.96 | 3.00 | 188.33        | 167.68  | 149.46  | 112.34 |
|                              | ShareGPT      | 3.83                | 3.03 | 1.97 | 1.10 | 255.15        | 244.73  | 214.05  | 171.65 |
|                              | Alpaca        | 3.91                | 2.19 | 2.06 | 1.26 | 117.35        | 98.59   | 97.66   | 71.79  |
| Qwen3-30B-A3B-Instruct-2507  | LMSYS-Chat-1M | 8.07                | 3.40 | 2.95 | 1.59 | 150.18        | 109.49  | 96.26   | 73.62  |
|                              | ShareGPT      | 3.76                | 1.75 | 1.50 | 0.86 | 224.70        | 172.47  | 150.54  | 116.26 |
|                              | Alpaca        | 2.58                | 1.14 | 0.82 | 0.49 | 59.72         | 40.82   | 35.55   | 29.88  |
| Qwen3-Next-80B-A3B-Instruct  | LMSYS-Chat-1M | 9.60                | 3.53 | 4.51 | 2.86 | 201.17        | 141.52  | 141.35  | 109.97 |
|                              | ShareGPT      | 4.19                | 2.17 | 1.97 | 1.23 | 285.93        | 235.27  | 218.30  | 183.12 |
|                              | Alpaca        | 3.62                | 2.24 | 1.46 | 1.18 | 111.22        | 93.37   | 80.26   | 67.77  |
| DeepSeek-R1-Distill-Qwen-32B | LMSYS-Chat-1M | 2.71                | 1.86 | 1.98 | 1.46 | 1057.02       | 855.83  | 852.08  | 729.42 |
|                              | ShareGPT      | 2.42                | 1.87 | 1.82 | 1.52 | 1443.49       | 1280.86 | 1268.46 | 994.56 |
|                              | Alpaca        | 2.13                | 1.68 | 1.52 | 1.25 | 890.31        | 777.19  | 743.32  | 625.56 |
| Mistral-7B-Instruct-v0.3     | LMSYS-Chat-1M | 2.56                | 1.67 | 1.25 | 0.71 | 127.67        | 100.72  | 88.21   | 59.05  |
|                              | ShareGPT      | 1.19                | 0.82 | 0.79 | 0.57 | 174.43        | 143.29  | 131.63  | 97.71  |
|                              | Alpaca        | 1.34                | 0.94 | 0.81 | 0.47 | 86.13         | 67.72   | 64.18   | 45.04  |
| Mixtral-8x7B-Instruct-v0.1   | LMSYS-Chat-1M | 1.91                | 1.03 | 1.46 | 0.80 | 101.86        | 78.15   | 85.02   | 66.51  |
|                              | ShareGPT      | 1.24                | 0.75 | 0.90 | 0.60 | 137.17        | 114.01  | 117.99  | 94.13  |
|                              | Alpaca        | 1.31                | 0.88 | 0.71 | 0.51 | 76.27         | 63.83   | 59.28   | 42.90  |
| OpenPangu-Embedded-7B        | LMSYS-Chat-1M | 2.65                | 0.69 | 1.34 | 0.47 | 163.53        | 106.97  | 113.38  | 93.04  |
|                              | ShareGPT      | 1.64                | 0.57 | 0.75 | 0.36 | 270.92        | 213.25  | 212.58  | 190.33 |
|                              | Alpaca        | 1.46                | 0.47 | 0.55 | 0.30 | 109.42        | 72.27   | 74.92   | 63.47  |

度器，以保证 QoS 和稳定性 (Hu et al., 2019)。

## D. 补充实验

### D.1. 其他模型上的结果

第 6 节在 Meta-Llama-3-8B-Instruct 和 Meta-Llama-3-70B-Instruct 上评估策略。本附录增加七个不同模型族的模型以评估泛化：GPT-oss-20B (OpenAI, 2025)、Qwen3-30B-A3B-Instruct-2507 (Team, 2025)、Qwen3-Next-80B-A3B-Instruct (Team, 2025; Yang et al., 2025)、DeepSeek-R1-Distill-Qwen-32B (Guo et al., 2025)、Mistral-7B-Instruct-v0.3、Mixtral-8x7B-Instruct-v0.1、OpenPangu-Embedded-7B (Chen et al., 2025a)。其中 Qwen3-30B-A3B-Instruct-2507、Qwen3-Next-80B-A3B-Instruct 和 Mixtral-8x7B-Instruct-v0.1 采用 MoE 架构。除特别说明外，设置同第 6.1 节。

全部模型以 FP16 精度服务，使用张量并行。具体而言，Mistral-7B-Instruct-v0.3 和 OpenPangu-Embedded-7B 部署在单 GPU；GPT-oss-20B、Qwen3-30B-A3B-Instruct 和 DeepSeek-R1-Distill-Qwen-32B 使用 2 张 GPU；Mixtral-8x7B 使用 4 张；Qwen3-Next-80B-A3B 使用 8 张。

表 5 展示在线聊天、100 RPS 下各策略表现，表 6 展示离线 SDG。TIE 在所有设置中持续表现较强，体现泛化能力。

### D.2. 样本量敏感性

采样 1k 个提示词，每个重复生成 100 次拟合分布参数，作为基准。随后改变重复次数，计算估计参数相对于该基准的相对误差。

如图 7，即使重复次数较少， $\mu$  的估计误差仍较低，因为位置参数主要由长度分布的中心趋势决定，较快稳定。 $\sigma$  的误差则随重复次数增加而下降，因为尺度参数对尾部敏感，需要更多样本才能准确捕捉。

更多重复虽得到更准确估计，但显著增加预测器训练数据采集成本。为平衡准确性与成本，选择 20 次重复。

表 6. 不同模型的 SDG 调度性能比较, 使用 Alpaca 测试。

| 模型                                | 生成 3k 样本时间 (秒) ↓ |         |         |         | 3 分钟内吞吐量 ↑ |      |      |      |
|-----------------------------------|------------------|---------|---------|---------|------------|------|------|------|
|                                   | FCFS             | SSJF    | LTR     | TIE     | FCFS       | SSJF | LTR  | TIE  |
| GPT-oss-20B                       | 283.57           | 257.26  | 202.88  | 165.56  | 1828       | 1957 | 2654 | 3298 |
| Qwen3-30B-A3B-Instruct-2507 (MoE) | 176.27           | 152.69  | 106.53  | 68.80   | 3045       | 3511 | 4563 | 6419 |
| Qwen3-Next-80B-A3B-Instruct (MoE) | 271.22           | 233.51  | 156.85  | 123.91  | 1907       | 2193 | 3379 | 4316 |
| DeepSeek-R1-Distill-Qwen-32B      | 2058.48          | 1584.06 | 1524.46 | 1134.33 | 245        | 352  | 394  | 533  |
| Mistral-7B-Instruct-v0.3          | 238.95           | 175.88  | 196.77  | 123.07  | 2246       | 3077 | 2601 | 4173 |
| Mixtral-8x7B-Instruct-v0.1 (MoE)  | 259.16           | 201.36  | 144.94  | 105.06  | 2048       | 2619 | 3660 | 5020 |
| OpenPangu-Embedded-7B             | 272.33           | 132.13  | 143.07  | 97.60   | 1970       | 3850 | 3608 | 4784 |




图 7. 重复次数对参数估计准确性的影响。相对误差以每提示词重复 100 次所得估计为基准。

### D.3. 固定 $\nu$ 值的敏感性


实际拟合使用固定自由度  $\nu$ 。为确定其值, 将  $\nu$  从 1 变化到 10, 逐一拟合并计算 KS 检验平均 p 值。图 8 表明  $\nu = 3.5$  表现最佳。

### D.4. 按提示词类别的诊断统计

表 7. 1K×100 提示词数据 (第 3.1 节) 按类别的诊断统计。用 Qwen3-32B (思考模式) 分类; 生成模型为 Llama-3-8B-Instruct, 数据集为 LMSYS-Chat-1M。KS 通过率为 log-t 在  $p > 0.05$  下的通过率。

| 类型  | 类别       | 提示词数 | 偏度   | CV   | P90/P50 | P99/P50 | KS 通过率       |
|-----|----------|------|------|------|---------|---------|--------------|
| 结构化 | 翻译与改写    | 266  | 2.75 | 0.93 | 3.40    | 7.80    | <b>89.5%</b> |
|     | 事实问答与知识  | 292  | 3.54 | 1.22 | 4.63    | 11.87   | <b>93.5%</b> |
|     | 代码与结构化输出 | 158  | 2.79 | 0.87 | 2.99    | 6.86    | <b>94.4%</b> |
| 开放式 | 创意与开放式写作 | 165  | 3.42 | 1.12 | 5.60    | 13.00   | <b>95.7%</b> |
|     | 对话与角色扮演  | 82   | 2.68 | 1.35 | 7.50    | 16.50   | <b>95.2%</b> |
| 其他  |          | 37   | 3.00 | 1.45 | 9.50    | 17.50   | <b>94.0%</b> |
| 全部  |          | 1000 | 3.10 | 1.09 | 4.62    | 10.77   | <b>93.1%</b> |

为验证第 3.1 节观察到的重尾并非特定提示词类型独有, 我们用 Qwen3-32B (思考模式) 将  $1K \times 100$  提示词分为五类并分析尾部统计。表 7 显示, 所有类别均具有正偏度、高 P90/P50 比值和超过 89% 的 log-t KS 通过率, 确认重尾行为的普遍性。开放式类别比结构化类别尾部略重, 与其生成约束更弱一致。

图 8. 自由度参数  $\nu$  对拟合质量的影响。表 8. 不同训练规模 ( $K$  个提示词  $\times$  每个  $N$  次生成) 下, 100 RPS 的平均每 token 延迟 (秒/token)。模型: Llama-3-8B-Instruct; 数据集: LMSYS-Chat-1M。

| 训练数据            | TIE (本文)    | SSJF | LTR  |
|-----------------|-------------|------|------|
| 900K $\times$ 1 | —           | 1.95 | 1.55 |
| 45K $\times$ 20 | <b>0.67</b> | 2.31 | 2.42 |
| 20K $\times$ 20 | 0.88        | —    | —    |
| 20K $\times$ 10 | 1.07        | —    | —    |
| 15K $\times$ 10 | 1.58        | —    | —    |
| 10K $\times$ 10 | 2.26        | —    | —    |

#### D.5. 训练数据规模敏感性

改变训练规模 ( $K$  个提示词  $\times N$  次生成) 以评估数据效率。表 8 显示, 仅  $15K \times 10 = 150K$  次生成, 即 SSJF/LTR 使用的 900K 的约 1/6, TIE 已优于 SSJF 并接近 LTR; 默认  $45K \times 20$  持续优于二者。多次生成训练成本只支付一次, 可在 LLM 服务部署生命周期中摊销。

#### D.6. 采样温度敏感性

表 9. 100 RPS 的平均每 token 延迟 (秒/token)。所有调度器在温度 =0.7 训练, 在不同温度评估。模型: Llama-3-8B-Instruct; 数据集: LMSYS-Chat-1M。

| 温度          | TIE (本文) | SSJF | LTR  |
|-------------|----------|------|------|
| 0.4         | 0.84     | 1.98 | 1.63 |
| 0.7 (与训练相同) | 0.67     | 1.95 | 1.55 |
| 1.0         | 0.73     | 2.02 | 1.70 |
| 1.3         | 1.13     | 2.59 | 2.62 |
| 1.6         | 2.61     | 4.42 | 5.77 |

为评估跨解码配置的泛化, 在温度 0.7 训练所有调度器, 再于 0.4–1.6 测试。表 9 显示, 各温度下 TIE 均优于 SSJF 和 LTR。极端温度 ( $\geq 1.6$ ) 使输出不确定性剧增, 所有方法均退化; 但这种设置通常产生低质量输出, 实际较少采用 (Nguyen et al., 2025)。

#### D.7. 自适应 $\beta$ 的有效性

为验证自适应  $\beta$  设计 (式 12), 在多种请求速率下与固定  $\beta$  比较。表 10 表明, 最佳固定  $\beta$  随负载改变: 低 RPS 为 0.1, 中等为 0.3, 高 RPS 为 0.5。实际负载随时间波动, 没有单一固定  $\beta$  始终最优。自适应策略动态响应压力, 在各负载下均达到最佳或接近最佳表现。

表 10. 不同请求速率下，自适应和固定  $\beta$  的平均每 token 延迟 (秒/token)。模型：Llama-3-8B-Instruct；数据集：LMSYS-Chat-1M。粗体表示自适应  $\beta$ ，下划线表示各列最佳固定  $\beta$ 。

| $\beta$ | 10 RPS      | 30 RPS      | 60 RPS      | 100 RPS     | 200 RPS     |
|---------|-------------|-------------|-------------|-------------|-------------|
| 自适应     | <b>0.05</b> | <b>0.18</b> | <b>0.41</b> | <b>0.67</b> | <b>1.88</b> |
| 0.1     | <u>0.05</u> | 0.23        | 0.49        | 0.72        | 2.17        |
| 0.3     | 0.07        | <u>0.20</u> | <u>0.44</u> | 0.71        | 2.09        |
| 0.5     | 0.09        | 0.25        | 0.46        | <u>0.70</u> | <u>1.96</u> |
| 0.7     | 0.12        | 0.29        | 0.48        | 0.74        | 2.05        |

#### D.8. 与抢占调度比较

表 11. 不同 RPS 下 TIE 与 TRAIL 的平均每 token 延迟 (秒/token)。模型：Llama-3-8B-Instruct；数据集：LMSYS-Chat-1M。

| RPS      | 10          | 30          | 40          | 60          | 80          | 100         |
|----------|-------------|-------------|-------------|-------------|-------------|-------------|
| TIE (本文) | <b>0.05</b> | 0.18        | 0.25        | <b>0.41</b> | <b>0.54</b> | <b>0.67</b> |
| TRAIL    | 0.06        | <b>0.15</b> | <b>0.23</b> | 0.57        | 0.87        | 1.41        |

增加 TRAIL (Shahout et al., 2025) 作为基线；它是每生成一个 token 便重新预测的抢占调度器。表 11 显示，低负载 ( $\leq 40$  RPS) 时二者相近，TRAIL 略占优势。中高负载 ( $\geq 60$  RPS) 时，频繁抢占引起 KV 缓存驱逐和重新预填充开销，使 TRAIL 急剧退化。TIE 通过分布建模和风险感知评分从源头减少误排序，避免频繁抢占的开销。

#### D.9. 对 $\sigma$ 预测质量的稳健性

表 12. 不同  $\sigma$  噪声下的平均每 token 延迟 (秒/token)。 $\sigma_{\text{noise}}$  是预测  $\sigma$  上乘性噪声范围，即调度器使用  $(1 \pm \sigma_{\text{noise}}) \times$  预测  $\sigma$ 。模型：Llama-3-8B-Instruct；数据集：LMSYS-Chat-1M。

| RPS | TIE ( $\sigma_{\text{noise}}=0$ ) | TIE (0.1) | TIE (0.3) | TIE (0.5) | TIE (0.7) | SSJF | LTR  |
|-----|-----------------------------------|-----------|-----------|-----------|-----------|------|------|
| 60  | <b>0.41</b>                       | 0.43      | 0.49      | 0.55      | 0.60      | 0.91 | 0.76 |
| 100 | <b>0.67</b>                       | 0.77      | 1.05      | 1.34      | 1.66      | 1.95 | 1.55 |

通过将预测  $\sigma$  乘以  $(1 \pm \sigma_{\text{noise}})$ ，考察 TIE 对  $\sigma$  预测误差的稳健性。表 12 显示，性能随噪声平缓退化。即使  $\sigma_{\text{noise}} = 0.7$ ，TIE 仍与 SSJF、LTR 有竞争力，表明它对不完美  $\sigma$  估计并不脆弱。

#### D.10. SDG 完整热力图

本节给出 Alpaca 测试中 8B (图 9) 和 70B (图 10) 完整热力图。考虑整个长度分布使 TIE 使用更丰富信息，更准确预测可能的长度，体现为图中相似长度请求更紧密聚集。

### E. 未来工作

TIE 在 LLM 推理请求调度中表现较强，但仍有以下值得探索的方向：

- **其他分布族。**本文用 log-t 有效捕捉输出长度重尾。未来可探索混合模型或非参数分布，更好适应不同应用和领域的多样输出模式。
- **解码时动态更新分布。**当前 TIE 在解码开始前预测长度分布。未来可随 token 生成动态更新，利用中间解码状态逐步修正预测，进一步改善高输出不确定性请求的调度。
- **训练数据采集的在线适应。**同一提示词需多次生成才能拟合参数，这限制直接使用在线服务数据。可探索在线适应、少样本学习或自监督方法，缓解约束，并支持部署时持续改进模型。
- **扩展到其他应用。**除请求调度外，长度分布预测还可用于 KV 缓存管理，根据预测分布预分配内存，或提高 API 定价成本估计的准确性 (Jiang et al., 2021)。将该框架适配到这些场景是未来研究方向。




图 9. 8B 模型在 Alpaca 上使用不同策略时，完成时间与输出长度的完整热力图。




图 10. 70B 模型在 Alpaca 上使用不同策略时, 完成时间与输出长度的完整热力图。

## 译者补充：原图英文标注对照

**图 1：单提示词长度分布。** Output Length (tokens): 输出长度 (token); Probability Density: 概率密度; Observed Frequency: 观测频率; Log-t Fit: log-t 拟合; KS test: p: KS 检验 p 值。参数  $\mu = 5.7$ 、 $\sigma = 0.2$ 、 $\nu = 3.5$  和  $p = 0.8898$  均保留。

**图 2：整体评分流程。** Predictor: 预测器; Score Calculator: 得分计算器; Prompt: 提示词; Input: 输入; Encoder: 编码器; Feature Extractor: 特征提取器; Parameter Predictor: 参数预测器; Tok 1、Tok 2、Tok N: 第 1、第 2、第 N 个 token; CLS: 分类标记; Mean-pooling: 均值池化; Max-pooling: 最大池化; Fused Feature: 融合特征; MLP for  $\mu$ : 预测  $\mu$  的 MLP; MLP for  $\sigma$ : 预测  $\sigma$  的 MLP; Log-t Distribution: log-t 分布; Score: 得分。DeBERTa、分布参数、期望和 CVaR 等数学记号保持原样。

**图 3：异步调度流程。** Scheduler: 调度器; Waiting Queue: 等待队列; GPUs: GPU; New Request: 新请求; Req: 请求; Req 0: 请求 0; Running Batch: 运行批; Min-heap: 最小堆; Submit: 提交; Predictor: 预测器; Completed Req Exit: 已完成请求退出; a (main): a 主流程; b (add to predict): b 加入待预测队列; predict (batch): 批量预测; update: 更新; re-heapify: 重建堆。箭头、颜色及编号保持原样。

**图 4：在线聊天性能。** Requests Per Second (req/s): 每秒请求数 (请求/秒); Latency per Token (s/token): 每 token 延迟 (秒/token); TTFT (s): 首 token 时间 (秒); TIE (ours): TIE (本文)。FCFS、SSJF、LTR 是调度器名称。

**图 5 及附录完整热力图。** Output Length (tokens): 输出长度 (token); Completion Time (s): 完成时间 (秒); Count (log scale): 数量 (对数刻度); TIE (ours): TIE (本文)。全部数值、颜色尺度、8B/70B 模型规模和方法名保持原样。

**附录数据集长度分布图。** Prompt Length: 提示词长度; Output Length (8B model): 输出长度 (8B 模型); Output Length (70B model): 输出长度 (70B 模型); # Tokens: token 数; Density: 密度; Mean: 均值; Median: 中位数。模型、数据集名称及各面板统计数值均保留。

**附录重复次数与自由度图。** Sample Size: 样本量 (此图横轴是每提示词的重复生成次数); Relative Error (%): 相对误差 (%); Fixed Degree of Freedom ( $\nu$ ): 固定自由度 ( $\nu$ ); Average KS p-value: 平均 KS 检验 p 值。 $\mu$ 、 $\sigma$  图例及 5%、10% 参考线保持原样。

## 译者补充：原文范围与不一致之处

1. 本文的概率对象是请求输出长度，不是工作流边或分支。TIE 是请求级非抢占排序；解码中动态更新分布在原文中列为未来工作。
2. 重尾理论先引入依赖轨迹的终止概率，再假设可由生成开始时的固定有效终止率刻画，并对其零附近密度施加渐近条件。此附加混合模型假设不应解读成所有 LLM 解码无条件具有同一幂律尾部，也没有直接推导出经验使用的 log-t 分布族。
3. 附录将有效终止率称为“终止概率的几何平均”，但所给公式实际为一减去非终止概率的几何平均。译文保留原始公式和叙述；引用其数学含义时应据公式区分。尾部概率乘积的期望也需明确其轨迹概率测度，不能直接将一般自回归条件概率序列视为固定参数的独立伯努利过程。
4. 未封顶 log-t 的期望发散，实际得分使用  $\min(X, x_{\max})$  的有限期望；这是保留上限处概率质量的封顶删失，不是丢弃超限样本后重新归一化的截断。
5. 正文 CVaR 公式对应附录第二种情形，即  $\alpha < T_{\nu}(y_{\max})$ 。当分位数达到上限时，附录另规定 CVaR 等于上限。附录在此处以严格大于上限的零概率事件解释未定义性，但此前定义使用的是大于等于分位数：封顶分布在上限具有正概率质量。译文忠实保留该差异，未改写原有推导。
6. 摘要和引言将离线提升  $1.42\times$  表述为吞吐量提升；正文实验表中 LMSYS 训练、8B 模型下，LTR 的 time@3K 为 139.53 秒，TIE 为 98.12 秒，对应约 1.42 倍完成时间加速；固定三分钟生成量分别为 3672 和 4762，对应约 1.30 倍吞吐量。两种指标不能直接混用，原始数字及主张均已保留。
7. 正文说增加六个模型、其中三个 MoE；附录列出并实验七个额外模型。译文按各处原文保留。主文相关工作提及“第 1 节讨论的 SSJF 和 LTR”，但本 arXiv 源码相应引言段落处于注释中，正式译文只翻译有效正文。
8. 本文对一致性和稳健性的讨论，以及防饥饿机制的表述，不构成额外竞争比、随机调度最优性或连续批处理公平性定理。相同总生成样本数的训练设置也不等于相同独立提示词数量。